

ADAM: A METHOD FOR STOCHASTIC OPTIMIZATION

📅 Date	May 12, 2026
☰ Multi-select	# DL



arxiv.org

<https://arxiv.org/pdf/1412.6980>

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work 관련 연구

3. 제안 방법론

ALGORITHM

알고리즘의 주요 단계

Adam 업데이트 규칙 (ADAM'S UPDATE RULE)

Initialization Bias Correction (초기화 편향 보정)

Convergence Analysis (수렴 분석)

4. 실험 및 결과

4.1 로지스틱 회귀 (Logistic Regression)

4.2 다층 신경망 (Multi-layer Neural Networks)

4.3 합성곱 신경망 (Convolutional Neural Networks, CNN)

4.4 초기화 편향 보정의 효과 (VAE)

4.5 확장 (EXTENSIONS)

4.6 결과

5. 결론 (배운점)

1. 결론

2. 인사이트

1. Introduction

논문이 다루는 분야

확률적 목적 함수(stochastic objective functions)의 1차 기울기 기반 최적화(first-order gradient-based optimization) 분야를 다룸. 특히 기계 학습, 그 중에서도 대규모 데이터셋이나 고차원 매개변수 공간을 가진 딥러닝 모델의 최적화 분야

- **확률적 기울기 기반 최적화의 중요성:** 과학 및 공학의 수많은 문제는 스칼라 매개변수로 정의된 목적 함수를 최소화하거나 최대화하는 최적화 문제로 귀결되며, 특히 확률적(stochastic) 목적 함수에 대한 효율적인 최적화 기술이 필수적임
- **1차 기울기 방법으로서의 제한:** 딥러닝과 같이 매개변수 공간이 매우 넓은 고차원 문제에서는 계산 복잡도가 높은 고차(higher-order) 최적화 방법이 부적합하기 때문에, 이 논문은 오직 **1차(first-order) 기울기**만을 사용하는 방법론에 집중함
- 데이터 하위 샘플링(미니배치)뿐만 아니라 드롭아웃(dropout) 규제와 같은 다양한 노이즈가 포함된 목적 함수에서도 효과적으로 작동하는 최적화 도구를 목표로 함

해당 task에서 기존 연구 한계점

- **고차 최적화의 비효율성:** 고차원 매개변수 공간에서는 계산 비용 문제로 인해 고차 방법을 적용하기 어려움
- **기존 적응형 알고리즘의 보완 필요:** 기존의 SGD는 효율적이지만, 희소한 기울기(sparse gradients) 환경이나 비정상성(non-stationary) 환경에서 각각 강점을 가진 **AdaGrad**와 **RMSProp**의 장점을 통합하고 그 한계점(편향 문제 등)을 극복할 수 있는 새로운 대안이 요구됨

논문의 contributions

- **Adam 알고리즘 제안:** 기울기의 1차 모멘트(평균)와 2차 모멘트(비중심 분산)의 추정치를 활용하여 매개변수별로 개별적인 적응형 학습률을 계산하는 효율적인 알고리즘인 Adam을 제시
- AdaGrad와 RMSProp의 장점을 결합하여 다음과 같은 장점들을 복합적으로 제공
 - 매개변수 업데이트 크기가 기울기의 스케일 변화에 영향을 받지 않음
 - 유효 보폭(stepsize)이 설정된 하이퍼파라미터 α 에 의해 대략적으로 제한되어 안정적임

- **자동 step annealing 효과:** 신호 대 잡음비(SNR)가 작아짐에 따라 보폭이 자연스럽게 줄어드는 효과를 가짐
- 정적이지 않은(non-stationary) 목적 함수나 희소한 기울기 환경에서도 견고하게 작동함
- 온라인 볼록 최적화 프레임워크 내에서 최적의 수렴 속도(regret bound)를 이론적으로 증명하였으며, 다양한 모델(로지스틱 회귀, CNN 등)과 데이터셋을 통해 기존의 다른 최적화 방법들을 능가함을 입증함
- 대규모 데이터셋과 고차원 매개변수 문제를 해결할 수 있는 다재다능한 알고리즘임을 보여주었으며, 이후 섹션에서 초기화 편향 보정 기술과 수렴 분석 등을 상세히 다룸

2. Related Work 관련 연구

- **주요 관련 알고리즘:** Adam은 **RMSProp**과 **AdaGrad**의 장점을 결합하도록 설계됨
 - 기타 확률적 최적화: **vSGD**(기울기 추정치의 분산 기반), **AdaDelta**(곡률 추정 기반), **SFO**(Sum-of-Functions Optimizer, 준뉴턴 기반) 등
 - SFO는 미니배치 수에 비례하는 메모리 요구량을 가지지만, Adam은 메모리 효율이 뛰어나 GPU와 같이 메모리가 제한된 시스템에 더 적합함
- Adam은 자연 기울기 강하(NGD)처럼 데이터의 기하학적 구조에 적응하는 전처리기(preconditioner) 사용 → 피셔 정보 행렬의 대각 성분을 근사하는 것과 유사한 기여
 - Adam의 전처리기는 대각 피셔 정보 행렬근사의 역수의 제곱근으로 전처리해 더 보수적으로 적응함
- **RMSProp:** 모멘텀이 있는 버전이 가끔 사용되어옴.
 - 모멘텀 RMSProp은 재촉적된 기울기에 모멘텀을 사용해 매개변수 업데이트 vs Adam은 기울기의 1차 및 2차 모멘트의 이동 평균을 사용해 직접추정하는 업데이트
 - 모멘텀 RMSProp은 편향 보정항이 부족한 문제 - 희소한 기울기에 필요한 1에 가까운 β_2 값의 경우, 편향을 보정하지 않으면 매우 큰 보폭과 발산을 초래
- **AdaGrad:** 희소한 기울기에 잘 작동하는 알고리즘
 - β_2 를 아래에서 1에 무한히 가깝게 선택하면 Adam은 $\beta_1 = 0$, infinitesimal $1 - \beta_2$ 및 α 를 $1/t$ annealed 버전으로 교체한 Adam 버전과 대응됨

- Adam과 AdaGrad 사이의 이러한 직접적인 대응은 편향 보정 항을 제거할 때는 성립하지 않음; 편향 보정이 없으면 RMSProp에서처럼 1에 무한히 가까운 β_2 는 무한히 큰 편향과 무한히 큰 매개변수 업데이트를 초래함

3. 제안 방법론

ALGORITHM

Adam의 이름은 'Adaptive Moment Estimation'에서 유래되었으며, 각 매개변수마다 개별적인 적응형 학습률(adaptive learning rates)을 계산하는 것이 핵심

기울기의 1차 모멘트(평균)와 2차 모멘트(비중심 분산)의 적응적 추정치를 결합하여 각 매개변수마다 최적의 학습률을 자동으로 조절함!

다음은 Adam의 의사코드 알고리즘

Algorithm 1: *Adam*, our proposed algorithm for stochastic optimization. See section 2 for details, and for a slightly more efficient (but less clear) order of computation. g_t^2 indicates the elementwise square $g_t \odot g_t$. Good default settings for the tested machine learning problems are $\alpha = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$ and $\epsilon = 10^{-8}$. All operations on vectors are element-wise. With β_1^t and β_2^t we denote β_1 and β_2 to the power t .

Require: α : Stepsize

Require: $\beta_1, \beta_2 \in [0, 1)$: Exponential decay rates for the moment estimates

Require: $f(\theta)$: Stochastic objective function with parameters θ

Require: θ_0 : Initial parameter vector

$m_0 \leftarrow 0$ (Initialize 1st moment vector)

$v_0 \leftarrow 0$ (Initialize 2nd moment vector)

$t \leftarrow 0$ (Initialize timestep)

while θ_t not converged **do**

$t \leftarrow t + 1$

$g_t \leftarrow \nabla_{\theta} f_t(\theta_{t-1})$ (Get gradients w.r.t. stochastic objective at timestep t)

$m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$ (Update biased first moment estimate)

$v_t \leftarrow \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$ (Update biased second raw moment estimate)

$\hat{m}_t \leftarrow m_t / (1 - \beta_1^t)$ (Compute bias-corrected first moment estimate)

$\hat{v}_t \leftarrow v_t / (1 - \beta_2^t)$ (Compute bias-corrected second raw moment estimate)

$\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon)$ (Update parameters)

end while

return θ_t (Resulting parameters)

- Adam은 노이즈가 있는 목적 함수 ($f(\theta)$)의 기대값 ($E[f(\theta)]$)를 최소화하는 것을 목표로 함.

- 알고리즘은 매 타임스텝마다 기울기 g_t 를 계산하고, 이를 바탕으로 기울기의 1차 모멘트(평균)와 2차 원시 모멘트(비중심 분산)를 추정하여 매개변수를 업데이트함

알고리즘의 주요 단계

1. 기울기 계산 (g_t) : 현재 매개변수 (θ_{t-1})에서 목적 함수의 기울기를 구함

2. 모멘트 추정치 업데이트 (m_t, v_t)

지수 이동 평균을 사용하여 과거 정보를 반영함

- 1차 모멘트 (기울기의 방향과 관성 반영)

$$[m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t]$$

- 2차 원시 모멘트 (기울기 크기의 변동성 반영)

$$[v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2]$$

3. 초기화 편향 보정 ($\hat{m}_t, \hat{v}_t$)

(m_0, v_0)가 0으로 초기화되었기 때문에 초기 단계에서 추정치가 0으로 편향되는 것을 보정

- $\hat{m}_t = \frac{m_t}{1 - \beta_1^t}$

- $\hat{v}_t = \frac{v_t}{1 - \beta_2^t}$

4. 매개변수 업데이트

보정된 모멘트를 사용하여 보폭을 결정

- $\theta_t = \theta_{t-1} - \alpha \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}}$

Adam 업데이트 규칙 (ADAM'S UPDATE RULE)

Adam이 매개변수 공간에서 단계를 어떻게 결정하는지, 그리고 왜 이 규칙이 안정적인지에 대한 설명

1. 보폭의 유계성 (Bounded Stepsize) 및 신뢰 영역

- 유효 보폭의 한계: 매 타임스텝에서 실제로 이동하는 크기인 유효 단계 Δ_t 는 다음과 같이 계산

$$\Delta_t = \alpha \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t}}$$

- 상한선: 기울기가 매우 희소한(sparse) 특수한 경우를 제외하면, 유효 보폭은 거의 항상 하 이퍼파라미터 α 에 의해 상한선이 결정

$$|\Delta_t| \approx \alpha$$

- 신뢰 영역 (Trust Region)
 - 현재 매개변수 주변에 일종의 신뢰할 수 있는 영역을 설정하는 것
 - 현재의 기울기 정보가 유효하다고 판단되는 범위(즉, α) 안에서만 움직이게 함으로써, 너무 큰 보폭으로 인해 학습이 발산하는 것을 막음

2. 신호 대 잡음비 (SNR) 및 자동 어닐링

- SNR의 정의: 논문에서는 다음 비율을 신호 대 잡음비(Signal-to-Noise Ratio)라고 함

$$\frac{\hat{m}_t}{\sqrt{\hat{v}_t}}$$
- 자동 어닐링 (Automatic Annealing)
 - 기울기의 방향이 확실(신호가 큼)하면 SNR이 커져서 보폭이 α 에 가까워짐
 - 반면, 최적점에 가까워지거나 기울기가 불확실(잡음이 큼)해지면 SNR이 0에 가까워짐

결과적으로 유효 보폭이 0에 수렴하게 되는데, 이는 사용자가 별도의 스케줄링을 하지 않아도 스스로 학습률을 줄여가는(annealing) 효과를 냄

3. 기울기 스케일에 대한 불변성 (Scale Invariance)

- Adam 업데이트 규칙의 장점은 기울기의 크기를 일정 비율 c 로 rescaling하더라도 실제 업데이트 크기는 변하지 않음
- 분자의 1차 모멘트 ($\hat{m}_t$)가 c 배가 될 때, 분모의 2차 모멘트 ($\sqrt{\hat{v}_t}$)도 동일하게 c 배가 되어 서로 상쇄되기 때문

⇒ 다양한 크기의 기울기를 가진 데이터나 layer에서도 일관된 성능 보장

+) 부연 설명

- 비중심 분산 (Uncentered Variance): 2차 모멘트 (v_t)는 평균을 빼지 않은 제곱의 평균. $E[g_t^2]$ 형태를 추정하는 값이며, 이는 데이터의 변동성(분산)뿐만 아니라 기울기의 절대적인 크기 에너지를 담고 있어 학습률을 조절하는 척도가 됨
- ϵ (수치적 안정성 항): 분모가 0이 되는 것을 방지하기 위해 더해주는 아주 작은 값

논문은 알고리즘 1의 루프 내 마지막 세 줄을 재구성하여 계산 순서를 최적화함으로써 성능을 조금 더 높일 수 있다고 함

Initialization Bias Correction (초기화 편향 보정)

Adam은 기울기의 1차 및 2차 모멘트를 추정하기 위해 지수 이동 평균(Exponential Moving Average, EMA)을 사용하지만, 이 과정에서 발생하는 초기 편향 문제를 해결하기 위해 보정 메커니즘을 도입

$$\begin{aligned}
 v_t &= (1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} \cdot g_i^2 \\
 \mathbb{E}[v_t] &= \mathbb{E} \left[(1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} \cdot g_i^2 \right] \\
 &= \mathbb{E}[g_t^2] \cdot (1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} + \zeta \\
 &= \mathbb{E}[g_t^2] \cdot (1 - \beta_2^t) + \zeta
 \end{aligned}$$

편향 발생 원인

- 1차 모멘트 벡터 m_t 와 2차 원시 모멘트 벡터 v_t 는 모두 0으로 초기화
 $\Rightarrow$ 학습 초기 단계, 특히 감쇠율 (β_1, β_2) 가 1에 가까울 때 추정치가 0으로 편향되는 경향이 발생

수학적 유도 (2차 모멘트 예시)

- 타임스텝 t 에서의 지수 이동 평균 v_t 는 모든 이전 타임스텝의 기울기 제곱 g_i^2 에 대한 합수로 다음과 같이 전개됨

$$v_t = (1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} g_i^2$$

이에 대한 기대값을 취하면, $\mathbb{E}[v_t]$ 는 실제 2차 모멘트 $\mathbb{E}[g_t^2]$ 와 $(1 - \beta_2^t)$ 라는 항 사이의 관계를 갖게 됩니다.

만약 실제 모멘트가 stationary이라면 오차 항 ζ 는 0이 되며, 정적이지 않더라도 과거 기울기에 작은 가중치를 할당하도록 β_1 을 선택하여 이를 작게 유지할 수 있음

보정 방법

- 0으로 초기화함으로써 발생하는 $(1 - \beta_2^t)$ 항의 영향을 상쇄하기 위해, 추정치를 해당 값으로 나누어 **편향이 보정된 추정치** $\hat{m}_t, \hat{v}_t$ 를 계산

- $\hat{m}_t = \frac{m_t}{1-\beta_1^t}$
 $\hat{v}_t = \frac{v_t}{1-\beta_2^t}$

기울기가 희소한 경우(Sparse Gradients), 신뢰할 수 있는 추정치를 위해 1에 가까운 β_2 를 사용해야 함. 이 경우 보정이 없다면 초기 단계에서 비정상적으로 큰 보폭을 갖게 되어 모델이 발산할 위험이 커짐

Convergence Analysis (수렴 분석)

논문은 온라인 학습 프레임워크를 통해 Adam이 이론적으로 얼마나 안정적으로 수렴하는지를 분석함

$$R(T) = \sum_{t=1}^T [f_t(\theta_t) - f_t(\theta^*)]$$

Regret 프레임워크

- 임의의 볼록 비용 함수 시퀀스에 대해, 알고리즘의 예측값과 사후적으로 알게 된 최적의 고정 매개변수 값 사이의 누적 차이인 regret를 분석 지표로 사용
- Regret Bound: 온라인 학습 알고리즘이 내린 선택이 최적의 선택과 비교했을 때 얼마나 더 나쁜지를 나타내는 상한선. 이 값이 작을수록 알고리즘이 효율적으로 학습하고 있음을 의미

핵심 증명 결과

- Adam은 $O(\sqrt{T})$ 의 regret bound를 가짐을 증명함

이는 일반적인 온라인 볼록 최적화 문제에서 알려진 최선의 결과와 대응되는 수준이었고 평균 regret $\frac{R(T)}{T}$ 는 $[T \rightarrow \infty]$ 일 때 0으로 수렴함이 확인됨

적응형 최적화

- 데이터 특징(feature)이 희소한 경우, Adam과 같은 적응형 방법은 비적응형 방법의 $[O(\sqrt{dT})]$ 보다 개선된 $O\left(\frac{\log d}{\sqrt{T}}\right)$ 수준의 수렴 특성을 가질 수 있음. (여기서 d는 차원)

⇒ Adam은 데이터의 기하학적 구조에 적응하여 더 빠른 학습이 가능함을 이론적으로 뒷받침

하이퍼파라미터 조건

- 이론적 분석을 위해서는 기울기와 매개변수 사이의 거리가 bounded되어야 함. 시간이 지남에 따라 모멘텀 계수 β_1 을 0으로 decay시키는 것이 수렴에 중요함

+) 지수 이동 평균 (EMA)

최근 데이터에 더 높은 가중치를 부여하고, 오래된 데이터의 영향력을 지수적으로 감소시키면서 평균을 계산하는 방식

+) 어닐링 (Annealing)

학습 과정에서 학습률을 점진적으로 낮추어 최적점에 안정적으로 도달하게 하는 기법.

Adam은 SNR 값의 변화를 통해 이를 자동적으로 수행

4. 실험 및 결과

논문은 Adam의 실질적인 효율성을 입증하기 위해 다양한 기계 학습 모델과 데이터셋을 활용하여 기존의 최적화 알고리즘들과 비교 실험을 진행함. 모든 실험에서 하이퍼파라미터는 grid search를 통해 최적의 설정 사용

4.1 로지스틱 회귀 (Logistic Regression)

MNIST 데이터셋

- L2 규제가 포함된 다중 클래스 로지스틱 회귀 실험에서 Adam은 Nesterov momentum 이 적용된 SGD와 유사한 수렴 속도를 보임
- 두 방법 모두 AdaGrad보다 빠르게 수렴

IMDB 영화 리뷰 데이터셋 (희소 특징 문제)

- 10,000개의 단어 가방(Bag-of-Words, BoW) 특징을 가진 데이터셋은 매우 희소 (sparse)한 특성을 가짐
- 실험 결과, Adam은 AdaGrad와 대등하게 빠른 수렴 속도를 보였으며, 희소 특징 학습에 취약한 일반적인 SGD보다 훨씬 우수한 성능 입증




Figure 1: Logistic regression training negative log likelihood on MNIST images and IMDB movie reviews with 10,000 bag-of-words (BoW) feature vectors.

4.2 다층 신경망 (Multi-layer Neural Networks)

- **비결정적(Deterministic) 비용 함수:** 두 개의 은닉층(각 1000개 유닛, ReLU 활성화)을 가진 모델에서 Adam은 SFO (Sum-of-Functions Optimizer)와 비교
 - 결과: Adam은 반복 횟수뿐만 아니라 실제 계산 시간(wall-clock time) 면에서도 SFO보다 훨씬 빠른 진전을 보임. SFO는 곡률(curvature) 정보를 업데이트하는 비용 때문에 반복당 시간이 Adam보다 5~10배 더 느리고 메모리 요구량도 큼
- **확률적 규제 (Dropout):** 드롭아웃 노이즈가 포함된 훈련에서도 Adam은 다른 확률적 1차 미분 방법들(AdaGrad, RMSProp, SGD Nesterov 등)보다 더 우수한 수렴 성능을 보임




Figure 2: Training of multilayer neural networks on MNIST images. (a) Neural networks using dropout stochastic regularization. (b) Neural networks with deterministic cost function. We compare with the sum-of-functions (SFO) optimizer (Sohl-Dickstein et al., 2014)

4.3 합성곱 신경망 (Convolutional Neural Networks, CNN)

CIFAR-10 데이터셋: 여러 층의 컨볼루션과 풀링이 포함된 깊은 CNN 구조에서 실험 진행

- CNN의 가중치 공유(weight sharing) 특성상 각 층마다 기울기의 크기가 매우 다를 수 있음. Adam은 수동으로 층별 학습률을 조정할 필요 없이 스스로 적응
- 수렴 양상: 초기에는 Adam과 AdaGrad 모두 빠르게 손실을 낮추지만, 결국 Adam과 SGD가 AdaGrad보다 훨씬 빠르게 수렴

⇒ CNN에서 2차 모멘트 추정치 $\hat{v}_t$ 보다 1차 모멘트를 통한 미니배치 분산 감소 효과가 더 중요하게 작용했기 때문으로 분석됨




Figure 3: Convolutional neural networks training cost. (left) Training cost for the first three epochs. (right) Training cost over 45 epochs. CIFAR-10 with c64-c64-c128-1000 architecture.

4.4 초기화 편향 보정의 효과 (VAE)

변분 오토인코더 (Variational Autoencoder, VAE)

- 편향 보정 항의 유무가 학습 안정성에 미치는 영향을 평가
- 결과: 특히 $\beta_2 \rightarrow 1$ 인 경우(희소 기울기에 대응하기 위해 필요), 편향 보정 항이 없으면 훈련 초기 단계에서 심각한 불안정성과 발산이 발생함을 확인

Adam은 하이퍼파라미터 설정과 관계없이 RMSProp과 동등하거나 그 이상의 성능을 일관되게 보여줌




Figure 4: Effect of bias-correction terms (red line) versus no bias correction terms (green line) after 10 epochs (left) and 100 epochs (right) on the loss (y-axes) when learning a Variational Auto-Encoder (VAE) (Kingma & Welling, 2013), for different settings of stepsize α (x-axes) and hyper-parameters β_1 and β_2 .

4.5 확장 (EXTENSIONS)

1. AdaMax

Adam의 업데이트 규칙은 기울기를 과거 기울기들의 L_2 노름(norm)에 반비례하게 조절하는 방식. 이를 일반적인 L_p 노름으로 확장할 수 있으며, 특히 $p \rightarrow \infty$ 인 극한의 경우를 AdaMax라고 함

- 단순한 재귀 공식

무한 노름(infinity norm)을 사용하면 다음과 같은 매우 간단하고 수치적으로 안정적인 수식이 도출됨 $u_t = \max(\beta_2 \cdot u_{t-1}, |g_t|)$

$$\begin{aligned} v_t &= \beta_2^p v_{t-1} + (1 - \beta_2^p) |g_t|^p \\ &= (1 - \beta_2^p) \sum_{i=1}^t \beta_2^{p(t-i)} \cdot |g_i|^p \end{aligned}$$

- 장점
 - Adam과 달리 별도의 초기화 편향 보정 필요X
 - 매개변수 업데이트 크기의 상한선이 다음과 같이 단순하게 유지됨 $|\Delta_t| \leq \alpha$

Algorithm 2: *AdaMax*, a variant of Adam based on the infinity norm. See section 7.1 for details. Good default settings for the tested machine learning problems are $\alpha = 0.002$, $\beta_1 = 0.9$ and $\beta_2 = 0.999$. With β_1^t we denote β_1 to the power t . Here, $(\alpha/(1 - \beta_1^t))$ is the learning rate with the bias-correction term for the first moment. All operations on vectors are element-wise.

Require: α : Stepsize

Require: $\beta_1, \beta_2 \in [0, 1)$: Exponential decay rates

Require: $f(\theta)$: Stochastic objective function with parameters θ

Require: θ_0 : Initial parameter vector

$m_0 \leftarrow 0$ (Initialize 1st moment vector)

$u_0 \leftarrow 0$ (Initialize the exponentially weighted infinity norm)

$t \leftarrow 0$ (Initialize timestep)

while θ_t not converged **do**

$t \leftarrow t + 1$

$g_t \leftarrow \nabla_{\theta} f_t(\theta_{t-1})$ (Get gradients w.r.t. stochastic objective at timestep t)

$m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$ (Update biased first moment estimate)

$u_t \leftarrow \max(\beta_2 \cdot u_{t-1}, |g_t|)$ (Update the exponentially weighted infinity norm)

$\theta_t \leftarrow \theta_{t-1} - (\alpha/(1 - \beta_1^t)) \cdot m_t/u_t$ (Update parameters)

end while

return θ_t (Resulting parameters)

2. 시간 평균 (Temporal Averaging)

확률적 근사 환경(stochastic approximation)에서 마지막 매개변수 값은 노이즈가 많을 수 있으므로, 매개변수의 이동 평균을 취함으로써 일반화 성능을 높일 수 있음

- 구현: 알고리즘 루프 내에 다음 한 줄을 추가하여 간단하게 구현 가능

$$\bar{\theta}_t \leftarrow \beta_2 \cdot \bar{\theta}_{t-1} + (1 - \beta_2) \theta_t$$

- 보정: 여기서도 초기화 편향 보정을 위해 다음과 같이 사용할 수 있음

$$\hat{\theta}_t = \frac{\bar{\theta}_t}{1 - \beta_2^t}$$

4.6 결과

- 효율성: Adam은 구현이 간단하고 계산 효율적이며 메모리 요구량이 적은 확률적 목적 함수 최적화 알고리즘
- 희소 기울기를 잘 처리하는 AdaGrad의 장점과 non-stationary 목적 함수에 강한 RMSProp의 장점을 성공적으로 결합
- 이론적인 수렴 분석과 실증적인 실험 결과 모두에서 우수함을 증명
- 기계 학습 분야의 대규모 데이터셋과 고차원 매개변수 공간을 가진 다양한 비볼록(non-convex) 최적화 문제에 매우 견고하게 작동하는 다재다능한 도구임이 입증됨

5. 결론 (배운점)

1. 결론

Adam은 대규모 데이터셋과 고차원 매개변수 공간을 가진 기계 학습 문제에 매우 적합하고 강력한 최적화 알고리즘임. Adam은 구현이 간단하고 계산 효율적이며 메모리 요구량이 적을 뿐만 아니라, 특히 다음과 같은 환경에서 탁월한 성능을 보임

- **Non-stationary objectives:** 시간에 따라 데이터 분포가 변하는 문제
- **노이즈가 많거나 sparse gradients:** 데이터의 특징이 드물게 나타나는 경우

실험적으로 Adam은 로지스틱 회귀, 다층 신경망(MLP), 합성곱 신경망(CNN) 등 다양한 모델에서 기존의 SGD, AdaGrad, RMSProp보다 우수하거나 대등한 성능을 보였으며, 특히 계산 시간(wall-clock time) 대비 수렴 속도가 매우 빨랐음

2. 인사이트

① 초기화 편향 보정의 결정적 역할

가장 중요한 기술적 인사이트 중 하나는 초기화 편향 보정의 필요성이다. Adam과 RMSProp의 가장 큰 차이점은 이 보정 항의 유무이다. 기울기의 2차 모멘트 추정치(v_t)를 0으로 초기화하면, 특히 감쇠율(β_2)이 1에 가까울 때 초기 추정치가 0으로 강하게 편향된다. 만약 이 보정이 없다면, 초기에 유효 보폭이 비정상적으로 커져 알고리즘이 발산하게 된다.

② 신뢰 영역과 자동 어닐링

Adam은 단순히 학습률을 조정하는 것을 넘어 보폭 제어를 수행하며 업데이트 한다. 실제 업데이트 크기는 하이퍼파라미터 α 에 의해 대략적으로 제한되는데, 이는 현재 기울기 정보가 유효하다고 믿을 수 있는 신뢰 영역 안에서만 매개변수를 이동시키는 효과를 준다.

논문은 m^t/v^t 를 신호 대 잡음비(SNR)로 정의한다. 최적점에 가까워질수록 신호가 약해져 SNR이 낮아지고, 이에 따라 유효 보폭이 자연스럽게 줄어드는 자동 어닐링이 발생하여 정교한 최적화가 가능해진다.

③ 기울기 스케일 불변성

Adam은 기울기의 크기를 일정 비율(c)로 재조정하더라도 업데이트 크기가 변하지 않는다. 분자의 1차 모멘트와 분모의 2차 모멘트(제곱근)가 동일한 비율로 변하여 서로 상쇄되기 때문이다. 이 특성 덕분에 CNN처럼 층마다 기울기 스케일이 크게 다른 모델에서도 각 층에 맞는 학습률을 수동으로 설정할 필요 없이 적응적으로 최적의 학습률을 찾아낼 수 있다.

