

An Image is Worth 16x16 Words: Vision Transformers at Scale

≡ Multi-select

CV



arxiv.org

<https://arxiv.org/pdf/2010.11929>

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work 관련 연구

3. 제안 방법론

Main Idea

3.1 Vision Transformer(ViT)

3.2 Fine tuning and higher resolution

4. 실험 및 결과

4.1 SETUP

4.2 COMPARISON TO STATE OF THE ART

4.3 PRE-TRAINING DATA REQUIREMENTS

4.4 SCALING STUDY

4.5 INSPECTING VISION TRANSFORMER

4.6 SELF-SUPERVISION

5. CONCLUSION

5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

컴퓨터 비전(Computer Vision) 분야, 그중에서도 특히 이미지 인식(Image Recognition) 및 분류(Classification) task

해당 task에서 기존 연구 한계점

- 자연어 처리(NLP)에서는 트랜스포머(Transformer)가 표준이 되었으나, 비전 분야에서는 여전히 CNN(합성곱 신경망) 구조가 지배적이었음
- 트랜스포머의 핵심인 셀프 어텐션(self-attention)을 이미지에 적용하려는 시도가 있었으나, 대개 CNN 구조의 일부를 대체하거나 결합하는 수준에 그침
- 픽셀 단위로 attention을 적용하는 방식은 픽셀 수의 제곱에 비례하는 연산 비용이 발생하여 현실적인 이미지 크기에 적용하기 어려웠고, 이를 해결하기 위한 특수한 attention 패턴들은 현대적 하드웨어 가속기에서 효과적으로 확장되지 못했음

논문의 contributions

- **Pure Transformer:** CNN에 의존하지 않고 표준 트랜스포머 구조를 이미지 패치 시퀀스에 직접 적용해도 이미지 분류 task에서 매우 우수한 성능을 낼 수 있음을 입증함
- **확장성(Scalability):** 대규모 데이터셋(ImageNet-21k, JFT-300M)으로 사전 학습할 경우, 트랜스포머가 CNN의 고유한 특성(귀납적 편향, Inductive Bias) 부족을 데이터의 양으로 극복하고 성능을 압도함을 보여줌
 - 트랜스포머는 평행 이동 equivariance이나 locality와 같이 CNN에 내재된 귀납적 편향이 부족하여, 불충분한 데이터로 학습할 경우 일반화 X
- **효율성:** 최신 SOTA(State-of-the-Art) CNN 모델들과 비교했을 때, 훨씬 적은 컴퓨팅 자원으로도 사전 학습이 가능하며 우수한 성능을 달성


2. Related Work 관련 연구

- **트랜스포머의 NLP 성공:** 트랜스포머가 제안된 이후 BERT, GPT 등 대규모 모델들이 사전 학습 후 fine-tuning하는 방식으로 NLP의 표준이 됨 → 비전에서도 시도 연구
- **비전에서의 어텐션 적용 시도:**
 - 각 픽셀이 다른 모든 픽셀을 참조해야 함 → 픽셀 수에 대한 비용이 제곱으로 증가
 - 픽셀 주변의 국소적 영역에만 어텐션을 적용하거나, 희소 트랜스포머(Sparse Transformers)를 사용하는 등 다양한 근사 기법이 시도됨 → 복잡함

- 이미지를 패치 단위로 나누어 어텐션을 적용한 연구(Cordonnier 등의 모델)가 있었으나, 이는 작은 해상도의 이미지에만 국한됨
- **대규모 학습:** CNN의 성능이 데이터셋 크기에 따라 어떻게 확장되는지에 대한 연구들이 활발히 진행되어 왔으며, 본 논문은 이 흐름을 트랜스포머로 이어받음

3. 제안 방법론

Main Idea



- 모델 설계는 원본 트랜스포머 설계와 비슷하게 함. (확장 가능한 NLP 트랜스포머 구조와 효율적 구현을 그대로 사용 가능한 장점)

3.1 Vision Transformer(ViT)

- 이미지를 고정된 크기의 패치(Patches로 분할하고, 각 패치를 NLP에서의 토큰(단어)과 동일하게 취급하여 트랜스포머의 입력으로 제공
- 모델 구조:

1. Patch Embedding:

2D 이미지를 패치 시퀀스로 변환한 뒤, 이를 flatten하고 linear projection을 통해 고정된 차원(D)의 벡터로 매핑

a. 표준 트랜스포머는 토큰 임베딩의 1D 시퀀스를 입력으로 받기 때문

2. Learnable [class] 토큰:

BERT와 유사하게, 이미지 전체의 표현을 담기 위한 특별한 학습 가능 토큰을 패치 시퀀스 맨 앞에 추가함

a. 트랜스포머 인코더 출력에서의 이 토큰 상태는 이미지 표현 y 로 사용

b. 사전 학습과 파인튜닝 시 모두 분류 헤드가 이 위치에 부착됨

3. Position Embedding:

패치들의 위치 정보를 유지하기 위해 1D 위치 임베딩을 패치 임베딩에 추가함

a. 표준학습 가능한 1D 위치 임베딩 사용 (2D를 사용해도 큰 성능 향상X)

4. Transformer Encoder:

다중 헤드 셀프 어텐션(MSA)과 MLP 블록이 교대로 반복되며, 각 블록 이전에 LayerNorm(LN)을, 이후에 residual connection을 적용함

The MLP contains two layers with a GELU non-linearity.

$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \dots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{\text{pos}}, \quad \mathbf{E} \in \mathbb{R}^{(P^2 \cdot C) \times D}, \mathbf{E}_{\text{pos}} \in \mathbb{R}^{(N+1) \times D} \quad (1)$$

$$\mathbf{z}'_{\ell} = \text{MSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1}, \quad \ell = 1 \dots L \quad (2)$$

$$\mathbf{z}_{\ell} = \text{MLP}(\text{LN}(\mathbf{z}'_{\ell})) + \mathbf{z}'_{\ell}, \quad \ell = 1 \dots L \quad (3)$$

$$\mathbf{y} = \text{LN}(\mathbf{z}_L^0) \quad (4)$$

• Inductive Bias:

- CNN보다 이미지 특화적 귀납적 편향 적음(CNN과 달리 ViT는 이미지 특유의 locality이나 이동 불변성(translation equivariance)에 대한 가정이 거의 없음.)
 - CNN에서는 지역성, 2차원 근방 구조, 평행 이동 불변성이 모델 전체의 각 레이어에 내장
 - ViT에서는 오직 MLP 레이어만이 locality, translation equivariance이며, 셀프 어텐션 레이어는 전역적임
- 모델은 학습 과정에서 패치 간의 공간적 관계를 스스로 학습해야 함

• Hybrid Architecture:

- 원본 이미지 패치 대신 CNN의 특징 맵에서 입력 시퀀스를 형성
- 이 하이브리드 모델에서는 패치 임베딩 projection이 CNN 특징 맵에서 추출된 패치에 적용됨

3.2 Fine tuning and higher resolution

- 일반적으로 ViT를 대규모 데이터셋에서 사전 학습하고 더 작은 다운스트림 작업에 fine tuning함
- 사전 학습된 예측 헤드를 제거하고 zero로 초기화된 $D \times K$ feedforward 레이어 부착 (K 는 다운스트림 클래스 수)
- 사전 학습보다 높은 해상도에서 fine tuning 하는 것이 유익함
- 더 높은 해상도의 이미지를 입력할 때 패치 크기를 동일하게 유지하면 유효 시퀀스 길이가 길어짐
- ViT는 임의의 시퀀스 길이를 처리할 수 있지만 사전 학습된 위치 임베딩의 의미가 없어질 수 있으므로 원본 이미지에서의 위치에 따라 사전 학습된 위치 임베딩의 2D interpolation 수행

4. 실험 및 결과

- ResNet, ViT, 하이브리드 모델의 표현학습 능력 각각 평가 및 비교
- 다양한 크기의 데이터셋으로 사전학습, 많은 벤치마크 작업 평가

⇒ JFT-300M과 같은 대규모 데이터셋으로 사전 학습된 ViT-H/14 모델은

ImageNet(88.55%), CIFAR-100(94.55%) 등 주요 벤치마크에서 기존 SOTA 모델인 BiT-L 이나 Noisy Student를 능가

⇒ 사전 학습에 필요한 연산량(TPUv3-core-days) 측면에서도 기존 CNN 모델들보다 훨씬 경제적

4.1 SETUP

• Datasets:

- **사전 학습(Pre-training):** 모델 확장성을 탐구하기 위해 ILSVRC-2012 ImageNet(1k 클래스, 130만 장), ImageNet-21k(21k 클래스, 1,400만 장), 구글 내부 데이터셋인 JFT(18k 클래스, 3억 300만 장) 사용
- **전이 학습(Transfer):** ImageNet(Original/ReaL labels), CIFAR-10/100, Oxford-IIIT Pets, Oxford Flowers-102 등의 벤치마크와 19개 태스크로 구성된 **VTAB-1k** 분류 모음을 평가에 사용

• Model Variants:

- BERT의 구성을 기반으로 **Base, Large, Huge** 세 가지 모델을 설계
 - **ViT-Base:** 12 레이어, 768 hidden size, 86M 파라미터
 - **ViT-Large:** 24 레이어, 1024 hidden size, 307M 파라미터
 - **ViT-Huge:** 32 레이어, 1280 hidden size, 632M 파라미터

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

Table 1: Details of Vision Transformer model variants.

- 표기법: 'ViT-L/16'은 Large 모델에 16x16 입력 패치 크기 사용을 의미 → 패치 크기가 작을수록 시퀀스 길이가 길어져 계산 비용이 증가
- **Training & Fine Tuning:**
 - **사전 학습:** Adam 옵티마이저($\beta_1=0.9, \beta_2=0.999$), 배치 사이즈 4096, 높은 가중치 감쇠(Weight Decay) 0.1
 - **미세 조정:** 모멘텀 SGD, 배치 사이즈 512 사용, 사전 학습보다 더 높은 해상도(384, 512, 518 등)에서 수행 시 성능 향상됨을 확인
- **Metrics:**
 - **Fine-tuning accuracy:** 각 데이터셋에 모델을 fine tuning한 후 측정한 최종 정확도
 - **Few-shot accuracy:** fine tuning 비용이 클 경우를 대비해, frozen representation에서 부분집합 이미지를 선형 회귀로 매핑하여 얻은 정확도를 빠른 평가 지표로 사용

4.2 COMPARISON TO STATE OF THE ART

- ViT-H/14는 JFT-300M으로 사전 학습 시 ImageNet(88.55%), CIFAR-100(94.55%), VTAB(77.63%) 등 주요 벤치마크에서 기존 SOTA(BiT-L, Noisy Student) 능가함
- 컴퓨팅 효율성: ViT-L/16 모델은 동일한 JFT-300M 데이터셋에서 학습된 BiT-L보다 모든 태스크에서 우수한 성능을 보이면서도, 사전 학습에 필요한 컴퓨팅 자원은 약 14.5배 적게

소모함.

- 공개 데이터셋인 ImageNet-21k로 사전 학습된 ViT-L/16 역시 대부분의 데이터셋에서 경쟁력 있는 성능을 보여줌

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet ReaL	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k




Figure 2: Breakdown of VTAB performance in *Natural*, *Specialized*, and *Structured* task groups.

4.3 PRE-TRAINING DATA REQUIREMENTS

- ViT는 CNN보다 이미지 특화 귀납적 편향이 적기 때문에 데이터셋 크기가 매우 중요함. 실험 결과 대규모 학습이 귀납적 편향을 압도한다는 결론
- 작은 ImageNet 데이터셋에서는 ViT가 동일 크기 ResNet보다 낮은 정확도를 보였으나, 데이터 규모가 커질수록(ImageNet-21k → JFT-300M) 성능 역전이 일어남
- JFT 데이터셋의 무작위 부분집합(9M, 30M, 90M) 실험을 통해, 작은 규모에서는 합성곱의 귀납적 편향이 유용하지만 대규모에서는 데이터로부터 직접 패턴을 학습하는 것이 충분하고 심지어 유익함을 증명함




Figure 3: Transfer to ImageNet. While large ViT models perform worse than BiT ResNets (shaded area) when pre-trained on small datasets, they shine when pre-trained on larger datasets. Similarly, larger ViT variants overtake smaller ones as the dataset grows.




Figure 4: Linear few-shot evaluation on ImageNet versus pre-training size. ResNets perform better with smaller pre-training datasets but plateau sooner than ViT, which performs better with larger pre-training. ViT-b is ViT-B with all hidden dimensions halved.

4.4 SCALING STUDY

- JFT-300M을 이용한 확장성 연구 결과, Vision Transformer는 성능 대비 컴퓨팅 비용 측면에서 ResNet을 압도함
- 동일한 정확도를 달성하기 위해 ViT는 ResNet보다 약 2~4배 적은 계산량(exaFLOPs) 사용
- 하이브리드 모델은 아주 작은 계산 예산에서는 순수 ViT보다 약간 우수했으나, 모델 규모가 커짐에 따라 순수 ViT가 그 격차를 없앴
- ViT는 시도된 범위 내에서 성능 포화 징후를 보이지 않아 향후 더 큰 규모로의 확장 가능성을 시사함




Figure 5: Performance versus pre-training compute for different architectures: Vision Transformers, ResNets, and hybrids. Vision Transformers generally outperform ResNets with the same computational budget. Hybrids improve upon pure Transformers for smaller model sizes, but the gap vanishes for larger models.

4.5 INSPECTING VISION TRANSFORMER




Figure 6: Representative examples of attention from the output token to the input space. See Appendix [D.7](#) for details.

- **필터 분석:** 첫 번째 레이어에서 패치를 선형 projection 하는 필터들은 각 패치 내부의 미세 구조를 표현하기 위한 그럴듯한 기저 함수 형태를 학습
- **위치 임베딩:** 모델은 위치 임베딩 간의 유사성을 통해 이미지 내의 거리를 인코딩하며, 행-열 구조 등 이미지의 2D 토폴로지를 스스로 학습
- **어텐션 거리(Attention Distance):** 셀프 어텐션을 통해 ViT는 최하위 레이어에서도 이미지 전체의 정보 통합 가능. 실제로 일부 헤드는 최하위 층에서 이미 전역적인 어텐션을 수행하며, 층이 깊어질수록 모델은 분류에 의 미론적으로 중요한 영역에 집중함




Figure 7: **Left:** Filters of the initial linear embedding of RGB values of ViT-L/32. **Center:** Similarity of position embeddings of ViT-L/32. Tiles show the cosine similarity between the position embedding of the patch with the indicated row and column and the position embeddings of all other patches. **Right:** Size of attended area by head and network depth. Each dot shows the mean attention distance across images for one of 16 heads at one layer. See Appendix [D.7](#) for details.

4.6 SELF-SUPERVISION

- BERT에서 사용된 마스크드 언어 모델링을 모방하여 **마스크드 패치 예측(Masked Patch Prediction)** 실험 수행
- 입력 패치 시퀀스의 50%를 오염시키고 해당 패치의 평균 색상을 예측하는 방식으로 자기 지도 학습을 진행
- 자기 지도 학습으로 사전 학습된 ViT-B/16은 ImageNet에서 79.9%의 정확도를 기록했으며, 이는 처음부터 학습한 것보다 2% 향상된 결과이지만 대규모 지도 학습 사전 학습보다는 여전히 4% 뒤처지는 수치임

5. CONCLUSION

- **연구의 성과: 순수 트랜스포머의 비전 분야 성공**
 - 본 연구는 트랜스포머를 **이미지 인식에 직접적으로 적용**하는 방식 탐구
 - 기존의 셀프 어텐션을 사용한 연구들과 달리, 초기 패치 분할 단계를 제외하고는 아키텍처에 **이미지 특화 귀납적 편향(Inductive Bias)**을 도입하지 않음
⇒ 대신 이미지를 패치 시퀀스로 해석하고, NLP에서 사용되는 **표준 트랜스포머 인코더**를 그대로 사용해 처리
 - 이 단순하지만 확장 가능한 전략은 **대규모 데이터셋 사전 학습**과 결합될 때 훨씬 우수한 성능을 보였으며, 많은 이미지 분류 데이터셋에서 최첨단 성능(SOTA)을 달성하거나 능가함

- 성능뿐 아니라 사전 학습에 드는 **비용도 상대적으로 저렴함**
- **남겨진 과제 및 향후 연구 방향**
 - **다양한 태스크로의 확장:** 분류를 넘어 객체 탐지(Detection)나 세그멘테이션(Segmentation)과 같은 다른 컴퓨터 비전 태스크에 ViT를 적용하는 과제가 남음
 - **자기 지도 학습(Self-Supervised Learning):** 초기 실험을 통해 자기 지도 학습의 가능성을 확인했지만, 여전히 대규모 지도 학습(Supervised pre-training)과의 **성능 격차**가 존재함. 이를 좁히기 위한 추가적인 탐구가 필요.
 - **추가적인 확장성:** ViT 모델을 더 큰 규모로 확장한다면 성능이 더욱 향상될 가능성이 높음

5. 결론 (배운점)

논문의 결론

본 연구는 자연어 처리(NLP)에서 주로 사용되던 표준 트랜스포머 아키텍처를 최소한의 수정만으로 이미지 인식 태스크에 직접 적용하는 가능성을 보여줌

- Vision Transformer(ViT)는 초기 패치 추출 단계를 제외하고는 이미지 특화 inductive bias를 거의 도입하지 않았음에도, 대규모 데이터셋으로 사전 학습할 경우 기존 최신 CNN 모델들과 대등하거나 이를 능가하는 성능을 보임
- 최신 SOTA 모델들과 비교했을 때, ViT는 성능 대비 사전 학습에 필요한 컴퓨팅 자원을 훨씬 적게 소모한다는 장점이 있음
- 복잡한 이미지 특화 구조 대신 표준 트랜스포머 인코더를 그대로 사용하는 단순한 전략이 대규모 데이터셋과 결합될 때 매우 강력하고 확장 가능하다는 점을 보여줌

인사이트

- CNN은 locality나 translation equivariance 같은 지식을 모델 구조 자체에 내장하고 있어 데이터가 적을 때 유리하지만, 데이터가 충분히 많아지면 트랜스포머가 이러한 공간적 관계를 데이터로부터 처음부터 스스로 학습하며 결국 CNN의 구조적 한계를 넘을 수 있음
- CNN은 레이어를 깊게 쌓아서 점진적으로 receptive field를 넓혀가지만, ViT는 셀프 어텐션을 통해 최하위 레이어에서도 이미지 전체의 정보를 통합할 수 있음
- NLP에서 표준이 된 Transformer를 이미지 처리에 구현하기 위해 이미지 자체를 word 형식으로 치환한 발상이 놀라움. 정보 변환에 한계를 두지 않아야 이런 한계를 넘는 모델이 나

올 수 있는 것 같음