

Denoising Diffusion Probabilistic Models

📅 Date	May 19, 2026
☰ Multi-select	#CV



arxiv.org

<https://arxiv.org/pdf/2006.11239>

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work 관련 연구

3. 제안 방법론

4. 실험 및 결과

5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

비평형 열역학(nonequilibrium thermodynamics)의 원리에서 영감을 얻은 잠재 변수 모델인 확산 확률 모델(diffusion probabilistic models)을 이용한 고품질 이미지 합성 분야

해당 task에서 기존 연구 한계점

- 확산 모델은 정의하기 쉽고 훈련이 효율적이라는 장점이 있었지만, GAN(Generative Adversarial Networks)과 같은 기존 생성 모델들에 비해 고품질의 샘플을 생성할 수 있다는 것을 입증한 사례가 없었음

- 기존의 우도 기반(likelihood-based) 모델들은 사람이 인지하기 어려운 이미지의 세부 사항을 묘사하는 데 많은 정보를 소모한다는 특징이 있었음

논문의 contributions

- 확산 확률 모델이 **매우 높은 품질의 이미지 샘플을 생성**할 수 있음을 보임. CIFAR10 데이터셋에서 FID 3.17을 기록하며 당시 최고 수준(SOTA)을 달성
- 확산 모델과 **어닐링된 랑제빈 역학(annealed Langevin dynamics)**을 이용한 **노이즈 제거 점수 매칭(denoising score matching)** 사이의 새로운 연결 고리 발견
- 가중치가 적용된 변분 경계(weighted variational bound)를 단순화한 ****새로운 손실 함수(L_{simple})****를 제안하여 샘플 품질을 최적화
- 확산 모델의 샘플링 과정이 autoregressive 디코딩의 일반화된 형태인 **점진적 손실 압축(progressive lossy decompression)** 방식으로 해석될 수 있음을 보여줌




Figure 1: Generated samples on CelebA-HQ 256×256 (left) and unconditional CIFAR10 (right)

34th Conference on Neural Information Processing Systems (NeurIPS 2020), Vancouver, Canada.

2. Related Work 관련 연구

- **기존 생성 모델:** DDPM은 Flow 기반 모델이나 VAE와 유사해 보일 수 있지만, 순방향 프로세스(q)에 학습 파라미터가 없고 최상위 잠재 변수(x_T)가 데이터(x_0)와 거의 상호 정보량

이 없도록 설계되었다는 점이 다름

- **Score Matching 및 에너지 기반 모델:** 이 논문은 확산 모델의 역방향 프로세스 매개변수화 방식이 여러 노이즈 수준에서의 노이즈 제거 점수 매칭 및 샘플링 시의 어닐링된 랑제빈 역학과의 동등성을 보여줌
- **Autoregressive 모델:** 가우시안 확산 모델을 데이터 좌표의 순서를 바꾸는 대신 일반화된 비트 순서를 사용하는 일종의 autoregressive 모델로 해석할 수 있다고 제안함

3. 제안 방법론

- **순방향 프로세스 (Forward Process, q):** 데이터 x_0 에 가우시안 노이즈를 단계적으로 추가하여 최종적으로 완전한 노이즈 x_T 를 만드는 마르코프 체인입니다. 분산 스케줄(β_t)에 따라 고정되며, 임의의 시점 t 의 샘플 x_t 를 닫힌 형태(closed form)로 직접 추출할 수 있음
- **역방향 프로세스 (Reverse Process, p_θ):** 가우시안 노이즈에서 원래 데이터를 복원하는 과정을 학습. 이 과정 또한 가우시안 전이로 정의되며, 모델은 각 단계에서 추가된 노이즈를 예측하도록 학습




Figure 2: The directed graphical model considered in this work.

- **매개변수화와 손실 함수:** 모델이 평균(μ)을 직접 예측하는 대신, **데이터에 추가된 노이즈(ϵ)를 예측하도록 매개변수화**했을 때 가장 좋은 결과를 얻음. 논문에선 이를 위해 다음과 같은 단순화된 손실 함수를 제안함

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\left\| \epsilon - \epsilon_\theta(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \epsilon, t) \right\|^2 \right] \quad (14)$$

- **네트워크 구조:** PixelCNN++의 백본을 기반으로 한 **U-Net 구조**를 사용하며, 그룹 정규화(Group Normalization)와 셀프 어텐션(Self-attention) 블록을 적용. 시간 정보 t 는 트랜스포머의 사인파 위치 임베딩을 통해 네트워크에 넣음

4. 실험 및 결과

- 데이터셋:

- CIFAR10, LSUN (Church, Bedroom, Cat), CelebA-HQ 256×256 데이터셋 사용
- CIFAR10에서 **FID 3.17, IS 9.46**을 기록하여 GAN보다 뛰어난 샘플 품질을 보여줌. LSUN 데이터셋에서도 ProgressiveGAN과 유사한 품질의 샘플을 생성

indicating that the majority of the bits are indeed allocated to imperceptible distortions.




Figure 5: Unconditional CIFAR10 test set rate-distortion vs. time. Distortion is measured in root mean squared error on a $[0, 255]$ scale. See Table 4 for details.

- Ablation 연구:

- 역방향 프로세스에서 평균(μ)을 예측하는 것보다 노이즈(ϵ)를 예측하고, 고정된 분산을 사용할 때 샘플 품질이 가장 높았음
- **Progressive Generation:** 샘플링 과정 초반에는 이미지의 거친 형태(low-frequency features)가 먼저 형성되고, 마지막 단계에서 미세한 디테일이 완성되는 특징을 보임
- **비트당 정보량 (NLL):** 무손실 코드 길이(lossless codelength) 면에서는 다른 우도 기반 모델들에 비해 경쟁력이 낮았으나, 이미지의 인지할 수 없는 세부 사항을 설명하는 데 대부분의 비트가 사용됨을 확인



Figure 6: Unconditional CIFAR10 progressive generation ($\hat{\mathbf{x}}_0$ over time, from left to right). Extended samples and sample quality metrics over time in the appendix (Figs. 10 and 14).



Figure 7: When conditioned on the same latent, CelebA-HQ 256×256 samples share high-level attributes. Bottom-right quadrants are $\mathbf{x}_t$, and other quadrants are samples from $p_\theta(\mathbf{x}_0|\mathbf{x}_t)$.



Figure 8: Interpolations of CelebA-HQ 256×256 images with 500 timesteps of diffusion.

5. 결론 (배운점)

- 확산 모델은 이미지 데이터에 대해 우수한 inductive bias를 가지고 있으며, 적절한 매개 변수화를 통해 매우 높은 품질의 샘플 생성이 가능
- 이 연구는 확산 모델이 단순히 새로운 생성 기법일 뿐만 아니라, 변분 추론, 점수 매칭, autoregressive 모델 및 손실 압축과 깊은 연관이 있음을 밝혀냄. 특히 노이즈를 예측하는 단순한 목적 함수가 고품질 이미지 생성에 매우 효과적이라는 점이 인상적이었음
- 확산 모델이 이미지 외의 다른 데이터 모달리티(음성, 비디오 등)나 다른 기계 학습 시스템의 구성 요소로서 어떻게 활용될 수 있을지에 대한 기대