

Generative Adversarial Nets

📅 Date	June 10, 2014
☰ Multi-select	# DL



arxiv.org

<https://arxiv.org/pdf/1406.2661>

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work 관련 연구

3. 제안 방법론

Adversarial Nets

이론적 결과 (Theoretical Results)

4. 실험 및 결과

5. 결론

장점 및 단점 (Advantages and Disadvantages)

결론 및 향후 과제 (Conclusions and Future Work)

1. Introduction

논문이 다루는 분야

딥러닝 기술을 활용하여 데이터의 확률 분포를 학습하고 새로운 데이터를 생성해내는 **심층 생성 모델(Deep Generative Models)** 분야

해당 task에서 기존 연구 한계점

당시 판별 모델(Discriminative Model)은 큰 성공을 거둔 반면, 생성 모델은 여러 어려움에 직면

- 최대 우도 추정(MLE) 등에서 발생하는 다루기 힘든 확률 계산(intractable probabilistic computations)을 근사화하는 것이 매우 어려웠음
- 생성 모델링 과정에서 ReLU와 같은 효율적인 piecewise linear units의 이점을 활용하기가 까다로웠음
 - 특히 마르코프 체인 피드백 루프를 사용하는 모델의 경우, 이러한 유닛을 쓰면 활성화 값이 무한히 커지는 문제가 발생
- RBM(제한된 볼츠만 머신)이나 DBM(심층 볼츠만 머신) 같은 비방향성 그래픽 모델은 확률 분포를 정규화하는 partition function와 그 그래디언트를 계산하는 것이 사실상 불가능해, **MCMC(마르코프 체인 몬테카를로)**방법에 의존해야 했음
 - MCMC는 **혼합(mixing) 문제**로 인해 학습 효율이 떨어지는 단점
- NCE(잡음 대조 추정)와 같은 방법은 **고정된 잡음 분포**를 사용하기 때문에, 모델이 관찰된 변수의 일부에 대해 대략적인 분포를 학습하고 나면 학습 속도가 급격히 느려지는 한계, 확률 밀도를 분석적으로 지정해야 하는 제약

논문의 contributions

- 데이터 분포를 학습하는 생성 모델(G)과 샘플의 출처(실제 데이터 vs 생성 데이터)를 판별하는 판별 모델(D)이 서로 경쟁하는 **최소최대 게임(minimax two-player game)** 구조를 새롭게 제안
- 이 모델은 학습이나 샘플 생성 과정에서 마르코프 체인이나 복잡한 근사 추론 네트워크가 전혀 필요하지 않음. 오직 forward propagation와 backpropagation, 드롭아웃 알고리즘만으로 전체 시스템을 훈련 가능.
- 마르코프 체인과 같은 피드백 루프가 없기 때문에, 그래디언트 계산에 유리한 piecewise linear units를 생성 모델 설계에 자유롭게 도입할 수 있게 됨.
- 생성 모델이 데이터 예제를 직접 복사하여 업데이트되지 않고 판별자를 통해 흐르는 그래디언트로만 학습되므로, 입력 데이터가 파라미터에 직접 복사되지 않는 통계적 장점.
 - 마르코프 체인 기반 방법들이 혼합을 위해 흐릿한 분포를 필요로 하는 것과 달리, 매우 날카롭거나 degenerate한 분포도 표현 가능
- 논문은 이 최소최대 게임이 생성자가 실제 데이터 분포를 완벽히 회복($p_g = p_{data}$)하는 유일한 전역 최적해를 가짐을 수학적으로 증명함

2. Related Work 관련 연구

1. 비방향성 그래픽 모델 (Undirected Graphical Models)

- **해당 모델:** 제한된 볼츠만 머신(RBM), 심층 볼츠만 머신(DBM) 및 그 변형들
- **특징:** 상호작용이 정규화되지 않은 전위 함수(potential functions)의 곱으로 표현되며, 모든 상태에 대한 글로벌 통합을 통해 정규화됨
- **한계점:** 정규화 상수(분할 함수, partition function)와 그래디언트가 대부분의 경우 계산 불가능(intractable)함. 이를 추정하기 위해 MCMC(마르코프 체인 몬테카를로) 방법을 사용하지만, MCMC는 혼합(mixing) 문제로 인해 학습 알고리즘에 상당한 어려움을 가짐

2. 하이브리드 모델 (Hybrid Models)

- **해당 모델:** 심층 신뢰망(DBN)
- **특징:** 하나의 비방향성 층과 여러 개의 방향성 층을 포함하는 혼합 구조
- **한계점:** 빠른 근사 층별 학습(layer-wise training) 기준이 존재하지만, 비방향성 모델과 방향성 모델이 가진 계산적 복잡성을 동시에 가짐

3. 대안적 기준 (Alternative Criteria)

- **해당 모델:** 점수 매칭(Score Matching), 잡음 대조 추정(NCE).
- **특징:** 로그 우도(log-likelihood)를 근사하거나 하한(lower bound)을 구하지 않는 방식
- **NCE와의 비교:** NCE는 본 논문과 유사하게 판별적 훈련 기준을 사용하여 생성 모델을 학습
- **NCE의 한계:** NCE는 별도의 판별 모델을 학습시키는 대신 생성 모델 자체를 사용하여 고정된 잡음 분포와 실제 데이터를 구분함.
→ 고정된 잡음 분포를 사용하게 되어, 모델이 데이터의 대략적인 분포를 학습한 이후에는 학습 속도가 급격히 느려지는 문제가 있음

4. 확률 분포를 명시하지 않는 생성 기법

- **해당 모델:** 생성적 확률 네트워크(GSN), 잡음 제거 오토인코더(DAE)
- **특징:** 확률 밀도를 정의하는 대신, 원하는 분포로부터 샘플을 추출하도록 생성 기계(generative machine)를 훈련
- **GSN과의 비교:** GSN은 매개변수화된 마르코프 체인을 정의하여 생성적 마르코프 체인의 한 단계를 학습하는 방식

- **GAN의 차별점:** GAN은 샘플링을 위해 마르코프 체인이 필요하지 않음. 또한 생성 과정에서 피드백 루프가 없기 때문에, 피드백 루프 내에서 활성화 값이 무한히 커질 수 있는 ReLU 등을 더 효과적으로 활용하여 역전파 성능을 높일 수 있음

5. 최근의 역전파 기반 모델

- **해당 모델:** 변분 오토인코더(VAE), 확률적 역전파(Stochastic Backpropagation).
- **특징:** 생성 기계에 직접 역전파를 수행하여 훈련하는 최신 기법들. GAN 역시 마찬가지로 미분 가능한 함수라면 무엇이든 모델 설계에 포함할 수 있다는 유연성을 가짐.

기존 연구들은 계산 불가능한 확률 계산을 해결하기 위해 MCMC나 복잡한 근사 방식을 사용해야 했던 반면, GAN은 마르코프 체인 없이 오직 역전파와 판별적 경쟁을 통해 이러한 한계들을 극복하고자 함

3. 제안 방법론

Adversarial Nets


생성 모델(G)과 판별 모델(D)이 다층 퍼셉트론(MLP)일 때의 프레임워크

- **모델 정의:**
 - **생성자(G):** 입력 노이즈 변수 $p_z(z)$ 를 데이터 공간으로 매핑하는 함수 $G(z; \theta_g)$
 - **판별자(D):** 데이터 x 가 실제 데이터 분포(p_{data})에서 왔을 확률을 출력하는 함수 $D(x; \theta_d)$
- **가치 함수 (Value Function):** 두 모델은 가치 함수 $V(D, G)$ 를 사용하여 다음과 같은 최소최대 게임(minimax game)을 수행함.

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))] \quad (1)$$

- **훈련 전략:**
 - 학습 초기에는 G 가 생성한 샘플이 실제 데이터와 확연히 달라 D 가 높은 자신감으로 이를 거절하며, 이로 인해 $\log(1 - D(G(z)))$ 항의 그래디언트가 소실 될 수 있음
 - 이를 해결하기 위해 학습 초기에는 G 가 $\log(1 - D(G(z)))$ 를 최소화하는 대신 $\log D(G(z))$ 를 최대화하도록 훈련하여 더 강한 그래디언트를 확보함
 - **(a)** p_g 가 p_{data} 와 유사하고 D 가 어느 정도 정확한 상태에서 시작

- **(b)** 알고리즘의 내부 루프에서 D 가 훈련되어 $D * (x) = p_{data}(x)/(p_g(x) + p_{data}(x))$ 로 수렴
- **(c)** G 가 업데이트되면서 D 의 그래디언트가 $G(z)$ 를 데이터일 확률이 높은 영역으로 이동시킴
- **(d)** 충분한 훈련 후 $p_g = p_{data}$ 가 되면 D 는 더 이상 구분할 수 없게 되어 $D(x) = 1/2$ 이 됨



이론적 결과 (Theoretical Results)

본 논문은 비매개변수적 설정(모델의 용량이 무한하다고 가정)에서 알고리즘의 수렴성을 수학적으로 증명함

1) 전역 최적해: $p_g = p_{data}$ (Global Optimality)

- **최적의 판별자 (D):** 임의의 G 에 대해 가치 함수 $V(G, D)$ 를 최대화하는 최적의 판별자 DG^* 는 다음과 같음

$$D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

- 이는 x 가 주어졌을 때 그것이 실제 데이터($y = 1$)일 조건부 확률을 추정하는 것으로 해석가능
- **전역 최솟값의 달성:** 최적의 D 가 주어진 상태에서 G 의 가치 함수는 젠슨-샤넌 발산 (Jensen-Shannon Divergence, JSD)으로 재구성됨

$$C(G) = -\log(4) + 2 \cdot JSD(p_{data} \| p_g)$$

- JSD는 두 분포가 일치할 때만 0이 되고 항상 0 이상이므로, $C(G)$ 의 전역 최소값은 $p_g = p_{data}$ 일 때 $-\log 4$ 가 됨

2) 알고리즘 1의 수렴성 (Convergence of Algorithm 1)

- G 와 D 가 충분한 용량을 가지고 있고, 매 단계에서 D 가 주어진 G 에 대해 최적점에 도달할 수 있다면, p_g 는 결국 p_{data} 로 수렴함
- **수학적 근거:** $f(p_g) = \sup D V(p_g, D)$ 는 p_g 에 대해 볼록(convex) 함수이며, 이 함수의 subderivatives는 최댓값이 달성되는 지점에서의 미분값을 포함함. 따라서 작은 업데이트를 통해 p_g 는 전역 최적해로 수렴하게 됨
- 실제로는 MLP를 사용하여 매개변수 θ_g 를 최적화하므로 이론적 보장과는 달리 여러 임계점(critical points)이 존재할 수 있으나, 실험적으로 우수한 성능을 보여줌

4. 실험 및 결과

1. 실험 환경 및 데이터셋

- **사용 데이터셋:** MNIST, Toronto Face Database (TFD), CIFAR-10 세 가지 데이터셋 사용
- **모델 아키텍처:**
 - **생성자 (G):** 선형 정류 활성화 함수(ReLU)와 시그모이드 활성화 함수를 혼합하여 사용
 - **판별자 (D):** maxout 활성화 함수를 사용했으며, 훈련 시 드롭아웃(Dropout)을 적용
 - **입력 노이즈:** 이론적으로는 중간 층에도 노이즈를 넣을 수 있으나, 본 실험에서는 생성자의 최하단 레이어에만 노이즈를 입력으로 제공함

2. 정량적 평가 (Quantitative Evaluation)

- **평가 방법 (Gaussian Parzen Window):**
 - 생성 모델에서 직접적인 우도(likelihood) 계산이 불가능하므로, G 에서 생성된 샘플들에 Gaussian Parzen window를 피팅하여 테스트 데이터에 대한 로그 우도를 추정함
 - 가우시안의 표준편차(σ) 파라미터는 검증셋(validation set)을 통한 교차 검증으로 결정
- **실험 결과**


Model	MNIST	TFD
DBN [3]	138 ± 2	1909 ± 66
Stacked CAE [3]	121 ± 1.6	2110 ± 50
Deep GSN [6]	214 ± 1.1	1890 ± 29
Adversarial nets	225 ± 2	2057 ± 26

- **MNIST:** 225 ± 2 의 로그 우도를 기록하여 DBN, Stacked CAE, Deep GSN 등 기존 모델보다 우수하거나 대등한 성능을 보임
- **TFD:** 2057 ± 26 을 기록하여 기존 모델들과 경쟁력 있는 수치를 나타냄
- 저자들은 이 평가 방식이 분산이 높고 고차원 공간에서 성능이 떨어질 수 있다는 점을 인정하면서도, 현재 가능한 최선의 방법이라고 언급함

3. 정성적 평가 및 시각화 (Qualitative Evaluation)

- **샘플의 품질:**

- 생성된 샘플들은 기존의 심층 생성 모델 시각화와 달리, 은닉 유닛의 조건부 평균이 아닌 **모델 분포에서 직접 추출된 실제 샘플**
- 샘플링 과정이 마르코프 체인에 의존하지 않으므로, 각 샘플은 서로 **상관관계가 없는 독립적인 결과물임**
- 맨 오른쪽 열에는 생성된 샘플과 가장 유사한 실제 훈련 데이터를 배치하여, 모델이 단순히 데이터를 암기(memorize)하여 출력하는 것이 아님을 증명함



• 잠재 공간의 구조:

- 잠재 변수 z 공간에서의 좌표 간 linear interpolation을 통해 얻은 숫자들을 시각화
- 이를 통해 잠재 공간의 인자들이 의미 있는 변화를 만들어내며, 모델이 데이터의 핵심 특징을 잘 학습했음을 보여줌



Figure 3: Digits obtained by linearly interpolating between coordinates in z space of the full model.

4. 실험을 통해 확인된 GAN의 특징

- **샘플링 효율성:** 마르코프 체인이 필요 없어 샘플링 시 어려움이 없음
- 미분 가능한 함수라면 무엇이든 모델에 포함할 수 있어 설계가 자유로움
- 데이터 예제가 생성자의 파라미터에 직접 복사되지 않고 판별자의 그래디언트를 통해서만 학습되므로 통계적 이점이 있음

	Deep directed graphical models	Deep undirected graphical models	Generative autoencoders	Adversarial models
Training	Inference needed during training.	Inference needed during training. MCMC needed to approximate partition function gradient.	Enforced tradeoff between mixing and power of reconstruction generation	Synchronizing the discriminator with the generator. Helvetica.
Inference	Learned approximate inference	Variational inference	MCMC-based inference	Learned approximate inference
Sampling	No difficulties	Requires Markov chain	Requires Markov chain	No difficulties
Evaluating $p(x)$	Intractable, may be approximated with AIS	Intractable, may be approximated with AIS	Not explicitly represented, may be approximated with Parzen density estimation	Not explicitly represented, may be approximated with Parzen density estimation
Model design	Nearly all models incur extreme difficulty	Careful design needed to ensure multiple properties	Any differentiable function is theoretically permitted	Any differentiable function is theoretically permitted

Table 2: Challenges in generative modeling: a summary of the difficulties encountered by different approaches to deep generative modeling for each of the major operations involving a model.

실험을 통해 GAN은 기존 모델들과 비교했을 때 **정량적으로 우수한 우도 수치**를 기록했을 뿐만 아니라, **상관관계가 없는 선명한 샘플**을 생성하며 데이터를 단순히 복제하지 않는 고도의 일반화 능력을 갖추었음을 입증함

5. 결론

장점 및 단점 (Advantages and Disadvantages)

GAN) 프레임워크는 기존의 생성 모델들과 비교하여 다음과 같은 장단점을 가짐

- 단점:

- 생성 모델 $p_g(x)$ 에 대한 명시적인 표현 X
- 훈련 과정에서 D 와 G 사이의 정교한 동기화가 필수적임. 특히 볼츠만 머신의 negative chains를 업데이트하는 것과 유사하게, D 를 업데이트하지 않고 G 만 과도하게 학습시키면 X
- **Helvetica Scenario:** G 가 너무 많은 z 값을 동일한 x 값으로 매핑하여 데이터의 다양성을 충분히 모델링하지 못하고 한 점으로 수렴해버리는 모드 붕괴 현상이 발생할 수 있음

- **장점:**

- 마르코프 체인이 전혀 필요하지 않으며, 그래디언트를 얻기 위해 오직 역전파 (Backpropagation) 알고리즘만을 사용함. 학습 중에 별도의 추론(inference) 과정 필요X
- 미분 가능한 함수라면 무엇이든 모델에 통합할 수 있어 매우 다양한 함수를 활용할 수 있음
- 생성 네트워크가 데이터 예제로부터 직접 업데이트되지 않고 판별자를 통해 흐르는 그라디언트로만 학습되므로, 입력 데이터의 구성 요소가 생성자의 파라미터에 직접 복사되지 않음
- 마르코프 체인 기반 방법들은 체인이 모드 사이를 섞이기 위해 다소 흐릿한(blurry) 분포를 필요로 하지만, GAN은 매우 날카롭고 심지어 퇴화된(degenerate) 분포도 표현할 수 있음

결론 및 향후 과제 (Conclusions and Future Work)

1. 조건부 생성 모델 (Conditional Generative Models):

G 와 D 모두에 추가 정보 c 를 입력으로 제공하여 $p(x | c)$ 형태의 조건부 모델을 구현할 수 있음

2. 학습된 근사 추론 (Learned Approximate Inference):

x 가 주어졌을 때 z 를 예측하는 보조 네트워크를 훈련시켜 추론을 수행할 수 있음. 이는 기존의 wake-sleep 알고리즘과 유사하지만, 생성자 학습이 완료된 후에도 고정된 생성자에 대해 훈련할 수 있다는 장점이 있음

3. 조건부 확률 모델링:

파라미터를 공유하는 조건부 모델 제품군을 학습시킴으로써, 변수 부분 집합 S 에 대한 모든 조건부 확률 $p(x_S | x_{\neg S})$ 을 근사적으로 모델링할 수 있음

4. 준지도 학습 (Semi-supervised Learning):

라벨이 있는 데이터가 제한적인 상황에서, 판별자나 추론 네트워크에서 추출한 특성(features)을 활용하여 분류기의 성능을 향상시킬 수 있음

5. 효율성 개선:

G 와 D 를 조정하는 더 나은 방법이나 학습 중 z 를 샘플링할 더 나은 분포를 고안함으로써 학습 속도를 크게 가속화할 수 있음