

Squeeze-and-Excitation Networks

📅 Date	May 16, 2019
☰ Multi-select	# DL



arxiv.org

<https://arxiv.org/pdf/1709.01507>

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work 관련 연구

3. 제안 방법론

4. 실험 및 결과

5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

이 논문은 **합성곱 신경망(CNN)**의 구조 설계 및 **이미지 표현력(Representation)** 향상에 관한 연구를 다룸. 특히, CNN의 핵심 연산자인 컨볼루션이 공간(spatial) 및 채널(channel) 정보를 융합하여 특징을 추출하는 방식에 주목함

해당 task에서 기존 연구 한계점

이전의 많은 연구들은 네트워크의 성능을 높이기 위해 계층 구조 전체에서 공간적 상관관계 (spatial correlations)를 포착하거나 공간적 인코딩의 품질을 높이는 데 집중해 옴 (예:

Inception 모듈의 다중 스케일 처리 등)

반면, **채널 간의 관계**는 대개 표준 컨볼루션 필터에 의해 암묵적이고 국소적으로만 모델링되었으며, 채널 간의 동적이고 비선형적인 의존성을 명시적으로 모델링하는 메커니즘은 부족했음

논문의 contributions

- **Squeeze-and-Excitation(SE) 블록**이라는 새로운 구조적 단위를 제안.
⇒ 채널 간의 상호의존성을 명시적으로 모델링하여 채널별 특징 반응을 적응적으로 재교정(recalibrate)
- 제안된 SE 블록은 매우 가벼우며(computational lightweight), 기존의 최첨단 CNN 아키텍처에 약간의 계산 비용 추가만으로 즉시 통합되어 성능을 크게 향상시킴
- SENet 아키텍처를 통해 **ILSVRC 2017 분류 대회에서 1위**를 차지했으며, top-5 에러를 2.251%로 낮추어 전년도 우승 모델 대비 약 25%의 상대적 성능 향상을 달성했음

2. Related Work 관련 연구

- VGGNet, Inception 모델은 네트워크 깊이가 표현력 향상에 중요함을 보였으며, Batch Normalization(BN)은 학습을 안정화했음. ResNet은 identity 기반 스킵 연결을 통해 훨씬 더 깊은 네트워크 학습을 가능하게 함.
- **알고리즘적 구조 탐색**: neuro-evolution이나 강화 학습을 이용해 네트워크 구조를 자동으로 설계하려는 연구들이 진행되었음. SE 블록은 이러한 탐색 알고리즘의 원자 단위(atomic building block)로 사용될 수 있음.
- **주의(Attention) 및 게이팅 메커니즘**: 주의 기전은 가장 정보가 많은 성분에 연산 자원을 편향시키는 방법. 이전 연구들은 공간 주의와 채널 주의를 결합하여 복잡한 모듈(예: hourglass 모듈)을 사용하기도 했으나, **SE 블록은 계산 효율성이 뛰어난 가벼운 게이팅 메커니즘**을 통해 채널 관계를 모델링하는 데 초점을 맞춤

3. 제안 방법론

SE 블록은 크게 두 단계의 연산을 통해 특징 재교정을 수행함




Fig. 1. A Squeeze-and-Excitation block.

1. Squeeze: 글로벌 정보 임베딩 (Global Information Embedding)

- 컨볼루션 연산은 국소적인 수용장만 보기 때문에 전역적인 문맥 정보를 활용하기 어려움
- 이를 해결하기 위해 **Global Average Pooling**을 사용하여 공간 정보($H \times W$)를 압축 (Squeeze)하고, 각 채널의 통계적 정보를 나타내는 **채널 설명자(channel descriptor)**($1 \times 1 \times C$)를 생성

2. Excitation: 적응적 재교정 (Adaptive Recalibration)

- 압축된 정보를 바탕으로 채널 간의 비선형적인 상호작용을 포착함
- 두 개의 Fully-Connected(FC) 레이어로 구성된 **시그모이드 게이팅 메커니즘**을 사용
- 모델 복잡도를 제한하기 위해, 첫 번째 FC 레이어에서 감소 비율(reduction ratio) r^* 을 사용하여 차원을 축소한 후(ReLU 활성화), 두 번째 FC 레이어에서 다시 원래 채널 수로 복구함
- 최종적으로 얻은 채널별 가중치(s)를 원래 특징 맵(U)에 곱하여(Scale 연산) 중요도가 높은 특징은 강조하고 덜 유용한 특징은 억제함

SE 블록은 Inception(**Fig. 2**)이나 ResNet(**Fig. 3**)과 같은 기존 구조에 유연하게 삽입될 수 있음




Fig. 2. The schema of the original Inception module (left) and the SE-Inception module (right).




Fig. 3. The schema of the original Residual module (left) and the SE-ResNet module (right).

• 상세한 레이어 구성

TABLE 1

(Left) ResNet-50 [13]. (Middle) SE-ResNet-50. (Right) SE-ResNeXt-50 with a $32 \times 4d$ template. The shapes and operations with specific parameter settings of a residual building block are listed inside the brackets and the number of stacked blocks in a stage is presented outside. The inner brackets following by fc indicates the output dimension of the two fully connected layers in an SE module.

Output size	ResNet-50	SE-ResNet-50	SE-ResNeXt-50 ($32 \times 4d$)
112×112	conv, 7×7 , 64, stride 2		
56×56	max pool, 3×3 , stride 2		
	$\begin{bmatrix} \text{conv}, 1 \times 1, 64 \\ \text{conv}, 3 \times 3, 64 \\ \text{conv}, 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} \text{conv}, 1 \times 1, 64 \\ \text{conv}, 3 \times 3, 64 \\ \text{conv}, 1 \times 1, 256 \\ fc, [16, 256] \end{bmatrix} \times 3$	$\begin{bmatrix} \text{conv}, 1 \times 1, 128 \\ \text{conv}, 3 \times 3, 128 \\ \text{conv}, 1 \times 1, 256 \\ fc, [16, 256] \end{bmatrix} \times 3$
28×28	$\begin{bmatrix} \text{conv}, 1 \times 1, 128 \\ \text{conv}, 3 \times 3, 128 \\ \text{conv}, 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} \text{conv}, 1 \times 1, 128 \\ \text{conv}, 3 \times 3, 128 \\ \text{conv}, 1 \times 1, 512 \\ fc, [32, 512] \end{bmatrix} \times 4$	$\begin{bmatrix} \text{conv}, 1 \times 1, 256 \\ \text{conv}, 3 \times 3, 256 \\ \text{conv}, 1 \times 1, 512 \\ fc, [32, 512] \end{bmatrix} \times 4$
14×14	$\begin{bmatrix} \text{conv}, 1 \times 1, 256 \\ \text{conv}, 3 \times 3, 256 \\ \text{conv}, 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} \text{conv}, 1 \times 1, 256 \\ \text{conv}, 3 \times 3, 256 \\ \text{conv}, 1 \times 1, 1024 \\ fc, [64, 1024] \end{bmatrix} \times 6$	$\begin{bmatrix} \text{conv}, 1 \times 1, 512 \\ \text{conv}, 3 \times 3, 512 \\ \text{conv}, 1 \times 1, 1024 \\ fc, [64, 1024] \end{bmatrix} \times 6$
7×7	$\begin{bmatrix} \text{conv}, 1 \times 1, 512 \\ \text{conv}, 3 \times 3, 512 \\ \text{conv}, 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} \text{conv}, 1 \times 1, 512 \\ \text{conv}, 3 \times 3, 512 \\ \text{conv}, 1 \times 1, 2048 \\ fc, [128, 2048] \end{bmatrix} \times 3$	$\begin{bmatrix} \text{conv}, 1 \times 1, 1024 \\ \text{conv}, 3 \times 3, 1024 \\ \text{conv}, 1 \times 1, 2048 \\ fc, [128, 2048] \end{bmatrix} \times 3$
1×1	global average pool, 1000-d fc , softmax		

4. 실험 및 결과

- **ImageNet 분류 성능:** SE 블록은 ResNet, ResNeXt, VGG-16, MobileNet, ShuffleNet 등 거의 모든 기본 아키텍처에서 성능을 일관되게 향상시켰음
 - 특히 SE-ResNet-50은 에러율이 6.62%로, 연산량이 두 배 더 많은 ResNet-101(6.52%)에 근접하는 성능을 보임

TABLE 2

Single-crop error rates (%) on the ImageNet validation set and complexity comparisons. The *original* column refers to the results reported in the original papers (the results of ResNets are obtained from the website: <https://github.com/Kaiminghe/deep-residual-networks>). To enable a fair comparison, we re-train the baseline models and report the scores in the *re-implementation* column. The *SENet* column refers to the corresponding architectures in which SE blocks have been added. The numbers in brackets denote the performance improvement over the re-implemented baselines. † indicates that the model has been evaluated on the non-blacklisted subset of the validation set (this is discussed in more detail in [21]), which may slightly improve results. VGG-16 and SE-VGG-16 are trained with batch normalization.

	original		re-implementation			SENet		
	top-1 err.	top-5 err.	top-1 err.	top-5 err.	GFLOPs	top-1 err.	top-5 err.	GFLOPs
ResNet-50 [13]	24.7	7.8	24.80	7.48	3.86	23.29 _(1.51)	6.62 _(0.86)	3.87
ResNet-101 [13]	23.6	7.1	23.17	6.52	7.58	22.38 _(0.79)	6.07 _(0.45)	7.60
ResNet-152 [13]	23.0	6.7	22.42	6.34	11.30	21.57 _(0.85)	5.73 _(0.61)	11.32
ResNeXt-50 [19]	22.2	-	22.11	5.90	4.24	21.10 _(1.01)	5.49 _(0.41)	4.25
ResNeXt-101 [19]	21.2	5.6	21.18	5.57	7.99	20.70 _(0.48)	5.01 _(0.56)	8.00
VGG-16 [11]	-	-	27.02	8.81	15.47	25.22 _(1.80)	7.70 _(1.11)	15.48
BN-Inception [6]	25.2	7.82	25.38	7.89	2.03	24.23 _(1.15)	7.14 _(0.75)	2.04
Inception-ResNet-v2 [21]	19.9†	4.9†	20.37	5.21	11.75	19.80 _(0.57)	4.79 _(0.42)	11.76

TABLE 3

Single-crop error rates (%) on the ImageNet validation set and complexity comparisons. MobileNet refers to “1.0 MobileNet-224” in [64] and ShuffleNet refers to “ShuffleNet 1 × (g = 3)” in [65]. The numbers in brackets denote the performance improvement over the re-implementation.

	original		re-implementation				SENet			
	top-1 err.	top-5 err.	top-1 err.	top-5 err.	MFLOPs	Params	top-1 err.	top-5 err.	MFLOPs	Params
MobileNet [64]	29.4	-	28.4	9.4	569	4.2M	25.3 _(3.1)	7.7 _(1.7)	572	4.7M
ShuffleNet [65]	32.6	-	32.6	12.5	140	1.8M	31.0 _(1.6)	11.1 _(1.4)	142	2.4M

- **계산 복잡도:** ResNet-50 기준, GFLOPs는 약 0.26% 증가하고 추론 시간은 소폭 증가하는 데 그쳐 매우 효율적임을 입증했음
- **일반화 능력:** ImageNet뿐만 아니라 CIFAR-10/100 (Table 4, 5), Places365 (Table 6), 그리고 COCO 객체 탐지 과제 (Table 7)에서도 성능 향상이 관찰되어 강력한 일반화 능력을 보여줌

TABLE 4
Classification error (%) on CIFAR-10.

	original	SENet
ResNet-110 [14]	6.37	5.21
ResNet-164 [14]	5.46	4.39
WRN-16-8 [67]	4.27	3.88
Shake-Shake 26 2x96d [68] + Cutout [69]	2.56	2.12

TABLE 5
Classification error (%) on CIFAR-100.

	original	SENet
ResNet-110 [14]	26.88	23.85
ResNet-164 [14]	24.33	21.31
WRN-16-8 [67]	20.43	19.14
Shake-Even 29 2x4x64d [68] + Cutout [69]	15.85	15.41

TABLE 6
Single-crop error rates (%) on Places365 validation set.

	top-1 err.	top-5 err.
Places-365-CNN [72]	41.07	11.48
ResNet-152 (ours)	41.15	11.61
SE-ResNet-152	40.37	11.01

TABLE 7
Faster R-CNN object detection results (%) on COCO *minival* set.

	AP@IoU=0.5	AP
ResNet-50	57.9	38.0
SE-ResNet-50	61.0	40.4
ResNet-101	60.1	39.9
SE-ResNet-101	62.7	41.9

- **Ablation Study (요소별 실험):**
 - **감소 비율 r :** $r=16$ 이 정확도와 모델 복잡도 사이에서 가장 좋은 균형
 - **Squeeze 연산:** Global Average Pooling이 Max Pooling보다 약간 더 나은 결과

- **Excitation 연산:** Sigmoid 활성화 함수가 필수적이며, 다른 비선형 함수(ReLU, Tanh) 사용 시 성능이 하락

5. 결론 (배운점)

- SE 블록은 네트워크가 채널별 특징 간의 의존성을 학습하여 표현력을 스스로 강화하게 해 줌
- 네트워크의 앞쪽 레이어에서는 클래스에 관계없이 중요한 저수준 정보를 강조하고, 뒤쪽 레이어로 갈수록 특정 클래스에 특화된(class-specific) 특징을 선택적으로 활성화한다는 점이 시각화를 통해 확인됨
- 매우 적은 추가 파라미터와 연산량으로 기존 CNN의 성능 한계를 돌파할 수 있는 간단하고도 강력한 방법론임을 보여줌. 이 기법은 네트워크 가지치기(pruning)나 모델 압축 등 다른 과제에도 유용하게 활용될 수 있는 가능성을 제시함