

Swin Transformer: Hierarchical Vision Transformer using Shifted Windows

📅 Date	August 17, 2021
☰ Multi-select	#CV



arxiv.org

<https://arxiv.org/pdf/2103.14030>

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work 관련 연구

3. 제안 방법론

4. 실험 및 결과

5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

컴퓨터 비전 분야에서 General-purpose backbone으로 사용할 수 있는 새로운 비전 트랜스포머인 **Swin Transformer**를 제안함

해당 task에서 기존 연구 한계점

자연어 처리(NLP) 분야에서 성공적이었던 트랜스포머 모델을 컴퓨터 비전 분야에 그대로 적용할 때 발생하는 두 가지 주요한 도메인 차이가 있었음

- **시각적 개체의 스케일 차이 (Scale Variations):**

텍스트에서는 단어 토큰이 기본 처리 단위이지만, 이미지 내의 개체(Entity)들은 그 크기가 매우 다양함. 기존의 ViT(Vision Transformer)는 고정된 크기의 패치를 토큰으로 사용하기 때문에, 다양한 스케일의 모델링이 필수적인 객체 탐지(Object Detection)와 같은 작업에는 적합하지 않았음

- **고해상도 이미지의 연산 복잡도 (High Resolution & Computational Complexity):**

이미지의 픽셀 해상도는 텍스트의 단어 수보다 훨씬 높음. 기존 트랜스포머의 셀프 어텐션은 토큰 수의 **제곱(Quadratic)**에 비례하는 **연산 복잡도**를 가지기 때문에, 픽셀 수준의 밀집 예측(Dense prediction)이 필요한 **의미론적 분할(Semantic Segmentation)** 등 고해상도 작업에서 연산량이 기하급수적으로 늘어나 감당하기 어려워짐

- **단일 해상도 피쳐 맵 (Single-resolution Feature Maps):**

이전의 비전 트랜스포머 아키텍처들은 단일한 저해상도 피쳐 맵만을 생성함. 이는 피쳐 피라미드 네트워크(FPN)나 U-Net과 같이 여러 해상도의 피쳐 맵을 활용하는 기존의 효율적인 컴퓨터 비전 기법들을 적용하기 어렵게 함

논문의 contributions

Swin Transformer는 위에서 언급된 문제들을 해결하며 컴퓨터 비전의 General-purpose backbone으로 기능할 수 있도록 함

- **계층적 피쳐 맵 생성 (Hierarchical Feature Maps):**

- 작은 크기의 패치에서 시작하여 층이 깊어짐에 따라 인접한 패치들을 병합(Patch Merging)하는 구조를 도입
- 이를 통해 모델은 다양한 해상도의 표현을 학습할 수 있으며, 기존 CNN(VGG, ResNet 등)과 유사한 구조의 피쳐 맵을 생성하여 객체 탐지 및 분할 알고리즘에 쉽게 통합될 수 있음

- **선형적 연산 복잡도 달성 (Linear Computational Complexity):**

- 전체 이미지가 아닌, 겹치지 않는 로컬 윈도우(Local window) 내에서만 셀프 어텐션(W-MSA)을 수행함
- 각 윈도우 내의 패치 수를 고정함으로써 연산 복잡도를 이미지 크기에 비례하는 선형(Linear) 복잡도로 낮추어, 고해상도 이미지도 효율적으로 처리할 수 있게 함


- **이동된 윈도우 방식 (Shifted Window Scheme):**

- 단순히 윈도우를 나누면 윈도우 경계 간의 정보 교환이 단절되는 문제가 발생하는데, Swin Transformer는 연속된 레이어 사이에서 윈도우의 분할 위치를 이동(Shift)시킴
- 이 방식은 이전 레이어의 윈도우 경계를 가로질러 새로운 연결을 만들어줌으로써 모델의 표현력을 크게 향상시키며, 슬라이딩 윈도우 방식보다 훨씬 낮은 지연 시간 (Latency)으로 효율적인 연산이 가능함

- **뛰어난 성능과 범용성 입증:**

- 이미지 분류뿐만 아니라 객체 탐지, 의미론적 분할 등 다양한 비전 작업에서 당시 최고 수준(State-of-the-Art)의 성능 달성
- 특히 COCO 객체 탐지에서 기존 최고 기록을 +2.7 box AP 차이로, ADE20K 분할에서는 +3.2 mIoU 차이로 크게 경신하며 트랜스포머 기반 모델이 비전 백본으로서 강력한 잠재력이 있음을 증명

Swin Transformer는 이러한 설계를 통해 비전과 언어 모델링의 통합(Unified modeling)을 가속화할 수 있는 토대를 마련했다는 점에서 큰 의의가 있음



2. Related Work 관련 연구

- **CNN 및 변형들:** AlexNet 이후 VGG, ResNet, EfficientNet 등 더 깊고 효율적인 CNN 구조들이 비전 분야의 표준 백본으로 자리 잡아옴
- **셀프 어텐션 기반 백본:** 일부 연구에서는 CNN의 일부 층을 셀프 어텐션으로 대체하려는 시도가 있었으나, 슬라이딩 윈도우 방식의 구현 어려움으로 인해 실제 지연 시간(Latency)이 CNN보다 훨씬 길어지는 문제가 있었음
- **트랜스포머 기반 비전 백본:** ViT(Vision Transformer)는 이미지를 패치 단위로 나누어 트랜스포머를 직접 적용해 이미지 분류에서 혁신적인 성과를 거두었으나, 단일 해상도의 피쳐 맵과 제곱의 연산 복잡도 때문에 범용적인 비전 백본으로 쓰기에는 한계가 있었음

3. 제안 방법론




Figure 3. (a) The architecture of a Swin Transformer (Swin-T); (b) two successive Swin Transformer Blocks (notation presented with Eq. (3)). W-MSA and SW-MSA are multi-head self attention modules with regular and shifted windowing configurations, respectively.

- **전체 구조:** 입력 이미지를 패치로 나누고, 단계별로 패치 병합(Patch Merging) 레이어를 통해 해상도를 줄이면서 채널 수를 늘려나가는 계층 구조를 가짐. 이는 전형적인 CNN(VGG, ResNet 등)의 특징 맵 해상도와 유사한 구조를 만들어 기존의 다양한 비전 알고리즘에 쉽게 적용 가능하게 함
- **Swin Transformer Block:** 기존 트랜스포머의 MSA(Multi-head Self-Attention) 모듈을 W-MSA(Window-based MSA) 및 SW-MSA(Shifted Window-based MSA)**로 대체한 블록을 사용
- **Shifted Window Partitioning:**
 - **W-MSA:** 이미지를 겹치지 않는 고정된 크기($M \times M$)의 윈도우로 나누어 연산 효율을 높임
 - **SW-MSA:** 다음 층에서는 윈도우의 위치를 이전 층에 비해 절반 크기만큼 이동시켜 분할함. 이를 통해 이전 층에서 분리되어 있던 윈도우 간의 정보 교환이 가능해짐.
- **효율적인 배치 연산(Cyclic Shift):** 윈도우를 이동시키면 윈도우의 개수가 늘어나고 크기가 불규칙해지는 문제가 발생하는데, 이를 해결하기 위해 순환 이동(Cyclic Shift)과 **마스킹(Masking)** 기법을 도입하여 연산 효율을 유지함
- **상대적 위치 편향(Relative Position Bias):** 어텐션 계산 시 각 헤드에 상대적인 위치 정보를 담은 편향(Bias) 값을 더해줌으로써 공간적인 상관관계를 더 잘 학습하게 함

4. 실험 및 결과

- **이미지 분류 (ImageNet-1K):** Swin-T는 81.3%, Swin-L(22K 사전 학습)은 **87.3%의 Top-1 정확도**를 기록하며 DeiT나 ResNet 계열 모델보다 우수한 성능을 보임
- **객체 탐지 (COCO):** 다양한 프레임워크(Cascade Mask R-CNN 등)에서 기존 SOTA 모델들을 능가했으며, 특히 COCO test-dev에서 **58.7 box AP, 51.1 mask AP**를 달성하여 당시 최고 기록을 경신
- **의미론적 분할 (ADE20K):** val 세트에서 **53.5 mIoU**를 기록하며 이전 최고 성능 모델 (SETR) 대비 +3.2 mIoU의 큰 성능 향상을 보임
- **소거 연구 (Ablation Study):**
 - Shifted Window 기법을 사용하지 않았을 때보다 모든 과제에서 성능이 유의미하게 향상됨을 입증
 - 상대적 위치 편향(Relative position bias)이 절대적 위치 임베딩보다 시각 모델링에 더 효과적임을 확인

5. 결론 (배운점)

- **Swin Transformer**는 계층적 구조와 윈도우 기반 셀프 어텐션을 결합하여 **선형 연산 복잡도**를 달성한 혁신적인 모델
- **Shifted Window** 접근법은 로컬 연산의 효율성과 전역적인 정보 연결 모두 잡는 매우 효과적인 전략임을 보여줌
- 객체 탐지나 세그멘테이션과 같은 **밀집 예측(Dense prediction)** 작업에서는 비전 트랜스포머에서도 스케일 불변성(Translation invariance)을 유도하는 인덕티브 바이어스(Inductive bias)가 여전히 중요함을 배울 수 있었음
- 향후 시각 정보와 텍스트 정보를 통합하여 처리하는 **통합 모델링(Unified modeling)** 연구를 가속화할 것으로 기대됨