

You Only Look Once: Unified, Real-Time Object Detection

☰ Multi-select

CV



arxiv.org

<https://arxiv.org/pdf/1506.02640>

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work 관련 연구

3. 제안 방법론

Main Idea

4. 실험 및 결과

5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

컴퓨터 비전의 객체 탐지(Object Detection) 분야

- 객체 탐지란 이미지 내에 어떤 객체가 있는지, 그리고 그 객체들이 어디에 위치해 있는지 파악하는 기술
- 인간의 시각 시스템은 이미지를 보는 즉시 객체의 종류와 위치, 상호작용을 파악할 만큼 빠르고 정확하지만, 컴퓨터에게 이를 실시간으로 수행하게 하는 것은 매우 도전적인 과제였음

해당 task에서 기존 연구 한계점

기존의 객체 탐지 시스템들은 주로 **분류기(Classifier)**를 **재사용**하여 탐지를 수행했음

- **DPM(Deformable Parts Models)**: 슬라이딩 윈도우(Sliding Window) 방식을 사용하여 이미지 전체에 걸쳐 고정된 간격으로 분류기를 실행
- **R-CNN 계열**: 'Region Proposal' 방법을 사용하여 이미지 내에 객체가 있을 법한 후보 박스를 먼저 생성한 후, 해당 박스들에 대해 분류기를 실행함. 이후 포스트 프로세싱을 통해 박스를 정제하고 중복을 제거하는 과정을 거침
- 이러한 방식들은 파이프라인이 매우 복잡하며, 각 구성 요소(지역 제안, 분류, 박스 회귀 등)를 개별적으로 훈련시켜야 하므로 최적화가 어렵고 속도가 매우 느림
 - ex. R-CNN은 테스트 시 이미지 한 장당 40초 이상이 소요

논문의 contributions




Figure 1: The YOLO Detection System. Processing images with YOLO is simple and straightforward. Our system (1) resizes the input image to 448×448 , (2) runs a single convolutional network on the image, and (3) thresholds the resulting detections by the model's confidence.




Figure 2: The Model. Our system models detection as a regression problem. It divides the image into an $S \times S$ grid and for each grid cell predicts B bounding boxes, confidence for those boxes, and C class probabilities. These predictions are encoded as an $S \times S \times (B * 5 + C)$ tensor.

YOLO는 객체 탐지를 단일 회귀 문제(Single Regression Problem)로 재정의 → 기존의 한계 극복

1. 실시간 성능(Extreme Speed):

복잡한 파이프라인 대신 단일 신경망을 사용하므로 매우 빠름. 기본 모델은 초당 45프레임(FPS), 더 작은 Fast YOLO 모델은 **155 FPS**를 기록하며 실시간 처리가 가능함

2. Global Reasoning:

슬라이딩 윈도우나 지역 제안 방식과 달리, YOLO는 훈련 및 테스트 시 이미지 전체를 한 번에 봄.

⇒ 객체의 외형뿐 아니라 주변 맥락(Context) 정보까지 학습

→ 배경을 객체로 오인하는 배경 오류(Background Errors)를 Fast R-CNN 대비 절반 이

하로 줄임

3. 일반화 성능(Generalizable Representations):

자연 이미지로 학습한 후 예술 작품과 같은 새로운 영역에 적용했을 때도 DPM이나 R-CNN보다 훨씬 뛰어난 성능을 보임.

⇒ 새로운 도메인이나 예상치 못한 입력에도 견고하게 작동함을 의미

2. Related Work 관련 연구

- **DPM:** 슬라이딩 윈도우 방식을 사용하며 정적인 특징을 추출. YOLO는 이를 단일 신경망으로 통합하여 특징 추출부터 예측까지 동시에 수행함
- **R-CNN:** 지역 제안 방식을 사용하지만 매우 느림. YOLO는 그리드 시스템을 통해 제안 박스 수를 획기적으로 줄이고(약 98개 vs R-CNN 2000개) 통합된 모델을 제안함
- **기타 빠른 탐지기:** Fast/Faster R-CNN 등이 속도 개선을 시도했으나 여전히 실시간 성능에는 미치지 못함. YOLO는 파이프라인 자체를 없애고 설계 단계부터 속도를 고려함
- **MultiGrasp:** YOLO의 그리드 기반 예측 방식은 Redmon 등의 이전 연구인 MultiGrasp 시스템의 회귀 방식에서 영감을 받음

3. 제안 방법론

Main Idea

YOLO는 이미지의 픽셀로부터 바운딩 박스 좌표와 클래스 확률을 직접 예측하는 통합된 네트워크

- **그리드 분할:** 입력 이미지를 $S \times S$ 그리드로 나눔. 객체의 중심이 특정 그리드 셀에 위치하면, 해당 셀이 그 객체를 탐지해야함
- **바운딩 박스 및 신뢰도 예측:** 각 그리드 셀은 B 개의 바운딩 박스와 그 박스들에 대한 신뢰도 점수(Confidence Score)를 예측. 신뢰도는 모델이 박스 안에 객체가 있다고 믿는 정도와 예측된 박스가 얼마나 정확한지를 반영
- **클래스 확률 예측:** 각 셀은 객체가 존재한다는 조건하에 해당 객체가 어떤 클래스에 속하는지 나타내는 조건부 클래스 확률(C)을 예측
- **네트워크 구조:** 24개의 컨볼루션 레이어와 2개의 완전 연결 레이어로 구성(GoogLeNet 모델에서 영감). 최종 출력은 $S \times S \times (B \times 5 + C)$ 크기의 텐서가 됨




Figure 3: The Architecture. Our detection network has 24 convolutional layers followed by 2 fully connected layers. Alternating 1×1 convolutional layers reduce the features space from preceding layers. We pretrain the convolutional layers on the ImageNet classification task at half the resolution (224×224 input image) and then double the resolution for detection.

4. 실험 및 결과




Figure 6: Qualitative Results. YOLO running on sample artwork and natural images from the internet. It is mostly accurate although it does think one person is an airplane.




Figure 5: Generalization results on Picasso and People-Art datasets.




Figure 4: Error Analysis: Fast R-CNN vs. YOLO These charts show the percentage of localization and background errors in the top N detections for various categories ($N = \#$ objects in that category).

- PASCAL VOC 2007 데이터셋에서 YOLO는 63.4 mAP를 기록하며 실시간 성능을 유지함. Fast YOLO는 52.7 mAP로 기존 실시간 탐지기보다 두 배 이상 정확함
- Fast R-CNN과 비교했을 때, YOLO는 위치를 정확히 잡지 못하는 **Localization Error**가 주요 오류 원인이었으나, 배경을 객체로 착각하는 오류는 훨씬 적었음
- Fast R-CNN의 결과에 YOLO를 결합하여 배경 오류를 제거한 결과, mAP가 3.2% 향상되는 효과를 보임.
- Picasso 및 People-Art 데이터셋 실험 결과, 실제 이미지가 아닌 예술 작품 도메인에서도 YOLO가 가장 높은 일반화 성능을 보임

5. 결론 (배운점)

- 복잡한 파이프라인을 단일 회귀 문제로 단순화함으로써 극적인 속도 향상을 이룸
- 이미지 전체를 한 번에 보는 설계가 객체 탐지에서 배경 오인율을 낮추는 데 결정적인 역할을 함을 배움
- 실시간 성능과 문맥 이해력은 얻었지만, 작은 객체들이 묻혀 있는 경우나 정밀한 위치 파악 (Localization) 측면에서는 여전히 개선의 여지가 남아 있음